

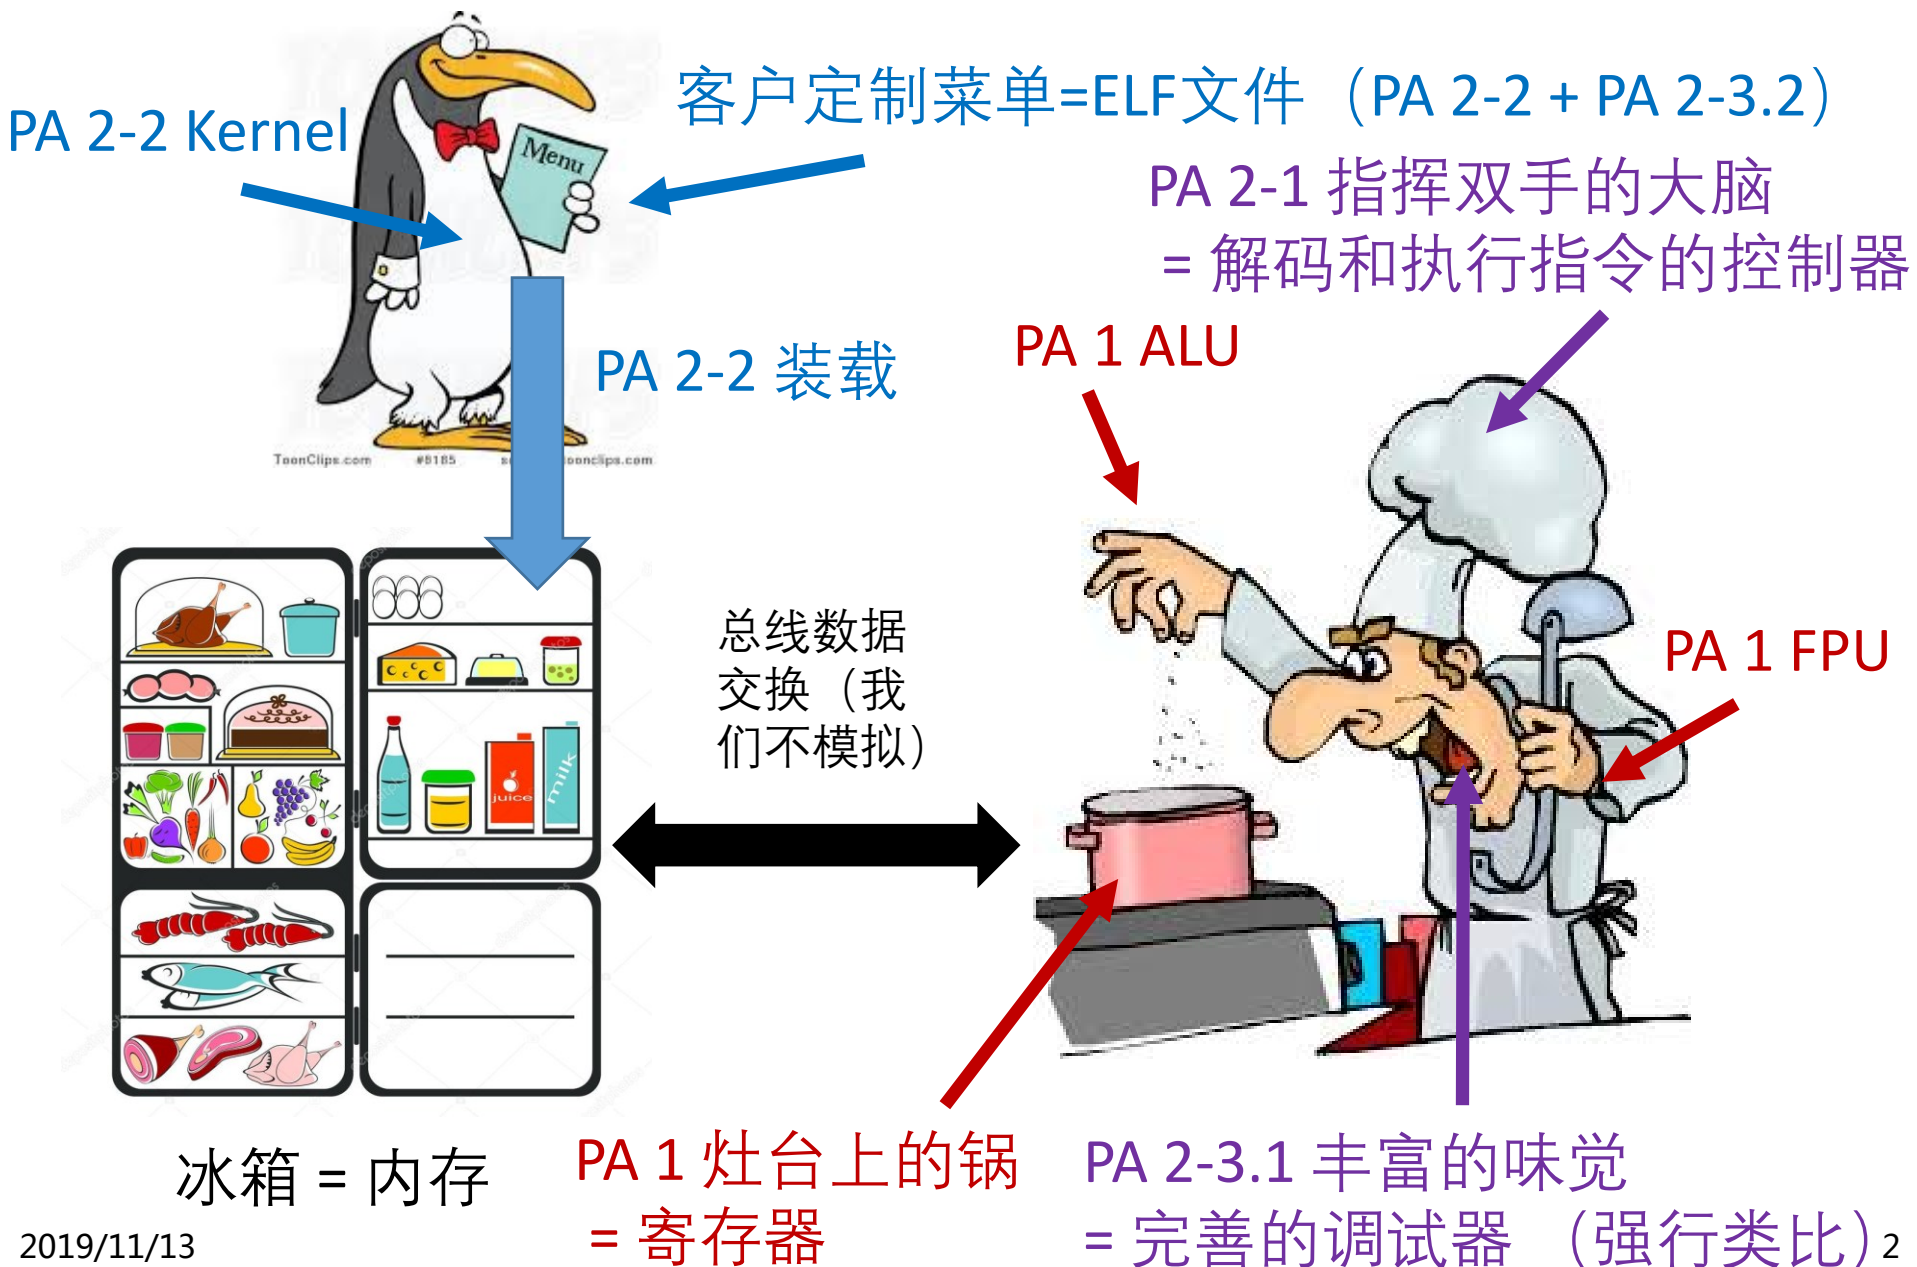
计算机系统基础
Programming Assignment

PA 3 存储管理

——PA 3-1 Cache的模拟

2019年11月13日

前情提要（以餐厅为类比）



PA 3的总体任务（以餐厅为类比）




对这一块有点不满意

PA 3-1 Cache的模拟

如何加快获取数据的速度？

PA 3-1 Cache的模拟

- 动机：频繁的访存大大影响了运算的速度
 - 每次取指令要访存
 - `instr_fetch()`
 - 每次取/存操作数要访存
 - `operand_read()` / `write()`
 - 调用 `vaddr_read()` / `write()`
 - 一条指令访存三四次，时间都花在访存上了



PA 3-1 Cache的模拟

- 怎么办？
 - 灶台（CPU芯片）上还有点空间，我放些小碟子来临时存放马上要用的东西（数据）
 - 这就是Cache，内存的Cache



后厨冰箱送出来，马上要烫的食材，在台面盘子里放好。要吃的时候直接盘子里夹。否则服务员一趟趟的跑，菜没吃几口，汤都烧干了。

内存里读出来，马上要用的数据，在Cache中摆好。要用的时候直接从Cache中读。否则每次都访存，指令没执行几条，时间都消耗了。

PA 3-1 Cache的模拟

- 基本原理：局部性
 - 时间局部性
 - 刚刚被访问过的数据很有可能再被访问（循环）
 - 刚刚被点过的菜很有可能再被点（四食堂的炒饭，每次有个人点个什么，他都炒一大锅一样的，马上就有人要）
 - 空间局部性
 - 刚刚被访问数据附近的数据很有可能马上再被访问（数组、指令序列）
 - 刚点过牛肉很可能马上再点羊肉

PA 3-1 Cache的模拟

- Cache设计时的三大问题
 - 问题一：Cache行和主存块的映射
 - 什么菜放什么盘子？
 - 问题二：Cache中主存块的替换算法
 - 盘子摆满了怎么办？
 - 问题三：Cache一致性问题
 - 盘子里的菜被改了怎么办？（这个问题没法类比.....）

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 什么菜放什么盘子？
 - 首先，盘子取多大？
 - 对主存和Cache都以相同的尺寸进行划分成单元
 - 设，都以 2^b 字节为大小进行划分
 - 主存中的一个单元叫一个主存块（block）
 - Cache中的一个单元叫一个Cache行（line）或槽（slot）

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 什么菜放什么盘子？
- 第二，主存块和Cache行怎么对应？
 - 直接映射
 - 一个萝卜一个盘~（坑->盘）
 - 全相联映射
 - 是盘就能占
 - 组相联映射
 - 划分成组，不能占别组的盘，但自己的组内是盘就能占

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法
 - 都以 2^b 字节为大小进行划分
 - 主存可以被划分成 2^m 个块
 - Cache的数据区提供了 2^c 个行
 - 如何一个萝卜一个盘？
 - 模映射法：内存中第M个块的块号 $M \bmod \text{Cache的行数}$
 - 对应到主存物理地址的划分？

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射

- 直接映射法

- 都以 2^b 字节为大小进行划分

- 主存可以被划分成 2^m 个块

- Cache的数据区提供了 2^c 个行

- 如何一个萝卜一个盘？

- 模映射法：内存中第M个块的块号M mod Cache的行数

- 对应到主存物理地址的划分？

高m位

低b位

块号

块内地址

第一步：主存划分成块

NEMU中 $m+b = 32$,
块号+块内地址确定物理地址

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射

- 直接映射法


- 都以 2^b 字节为大小进行划分
 - 主存可以被划分成 2^m 个块
 - Cache的数据区提供了 2^c 个行

- 如何一个萝卜一个盘？

- 模映射法：内存中第M个块的块号M mod Cache的行数
 - 对应到主存物理地址的划分？

NEMU中 $m+b = 32$,
块号+块内地址确定物理地址

标记+行号可确定
唯一块号



第一步：主存划分成块

第二步：所谓对块号取模
(2^c 个行)

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射

- 直接映射法
- Cache的组织

主存（物理）地址：



Cache行号（就是Cache行构成的数组之下标，不用显式给了）

Cache :	0	有效位	标记	2^b 字节块（行）内数据
	1	有效位	标记	2^b 字节块（行）内数据
	2	有效位	标记	2^b 字节块（行）内数据
	3	有效位	标记	2^b 字节块（行）内数据

额外的1比特有效位：为0表示Cache行无效，为1表示有效

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法
 - 所以说我有了主存物理地址，我想读数据，怎么知道它对应Cache里的哪一行？在不在Cache里？

主存（物理）
地址：



Cache : 0

1

2

3

有效位	标记	2 ^b 字节块（行）内数据
有效位	标记	2 ^b 字节块（行）内数据
有效位	标记	2 ^b 字节块（行）内数据
有效位	标记	2 ^b 字节块（行）内数据

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法
 - 所以说我有了主存物理地址，我想读数据，怎么知道它对应Cache里的哪一行？在不在Cache里？

第一步：找行号

主存（物理）
地址：



Cache : 0

1

2

3

有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法
 - 所以说我有了主存物理地址，我想读数据，怎么知道它对应Cache里的哪一行？在不在Cache里？

主存（物理）
地址：



第一步：找行号

第二步：比标记

- 相等？有希望！继续
- 不等？没希望！读内存块去

Cache : 0

1

2

3

有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射

- 直接映射法

- 所以说我有了主存物理地址，我想读数据，怎么知道它对应Cache里的哪一行？在不在Cache里？

主存（物理）
地址：



第一步：找行号

第二步：比标记

- 相等？有希望！继续
- 不等？没希望！读内存块去

第三步：看有效位

- 为1？中！读Cache
- 为0？没中！读内存块去

Cache : 0

1

2

3

有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据
有效位	标记	2^b 字节块（行）内数据

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法
 - 所以说我有了主存物理地址，我想读数据，怎么知道它对应Cache里的哪一行？在不在Cache里？

主存（物理）
地址：



第一步：找行号

第二步：比标记

- 相等？有希望！继续
- 不等？没希望！读内存块去

第三步：看有效位

- 为1？中！读cache
- 为0？没中！读内存块去

Cache : 0
1
2
3

有效位	标记	2 ^b 字节块（行）内数据
有效位	标记	2 ^b 字节块（行）内数据
有效位	标记	2 ^b 字节块（行）内数据
有效位	标记	2 ^b 字节块（行）内数据

第四步：如命中，按照块内地址读cache

第四步*：如不命中，按照物理内存读主存，把块搬入cache，填好标记和有效位，按照块内地址读cache

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 理解直接映射法的基础上
 - 全相联映射：是坑就占

NEMU中 $m+b = 32$,
块号+块内地址确定物理地址

高 m 位

低 b 位

块号

块内地址

根据主存物理地址找Cache行的时候就拿块号和标记一个个去比，比到一样的就是命中

Cache行号（没用了） m 位

0	有效位	标记	2^b 字节块（行）内数据
1	有效位	标记	2^b 字节块（行）内数据
2	有效位	标记	2^b 字节块（行）内数据
3	有效位	标记	2^b 字节块（行）内数据

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法的基础上
 - 组相联映射：折中方案
 - Cache的数据区提供了 2^c 个行
 - 划分成 2^q 个组（q肯定小于c）
 - 一个组里有 $2^s = 2^{c-q}$ 行，称为 2^s 路组相联

PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法的基础上
 - 组相联映射：折中方案
 - Cache的数据区提供了 2^c 个行
 - 划分成 2^q 个组（q肯定小于c）
 - 一个组里有 $2^s = 2^{c-q}$ 行，称为 2^s 路组相联

主存（物理）地址：



PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 直接映射法的基础上
 - 组相联映射：折中方案
 - 有了物理地址找到Cache行的过程（动画省略，课本pg. 252）
 - 第一步：根据组号找到相应的组
 - 起始行号就是组号乘以多少路组相联？
 - 第二步：组内的Cache行一个个比标记，命中？不命中？
 - 第三步：看有效位，命中？不命中？
 - 第四步：命中？读Cache：不命中？先搬主存块到Cache，再读Cache

主存（物理）地址：

Cache组织（课本pg. 251）



PA 3-1 Cache的模拟

- 问题一：Cache行和主存块的映射
 - 什么菜放什么盘子？
- 第二，主存块和Cache行怎么对应？
 - 直接映射
 - 一个萝卜一个盘~（坑->盘）
 - 全相联映射
 - 是盘就能占
 - 组相联映射
 - 划分成组，不能占别组的盘，但自己的组内是盘就能占

各有优劣

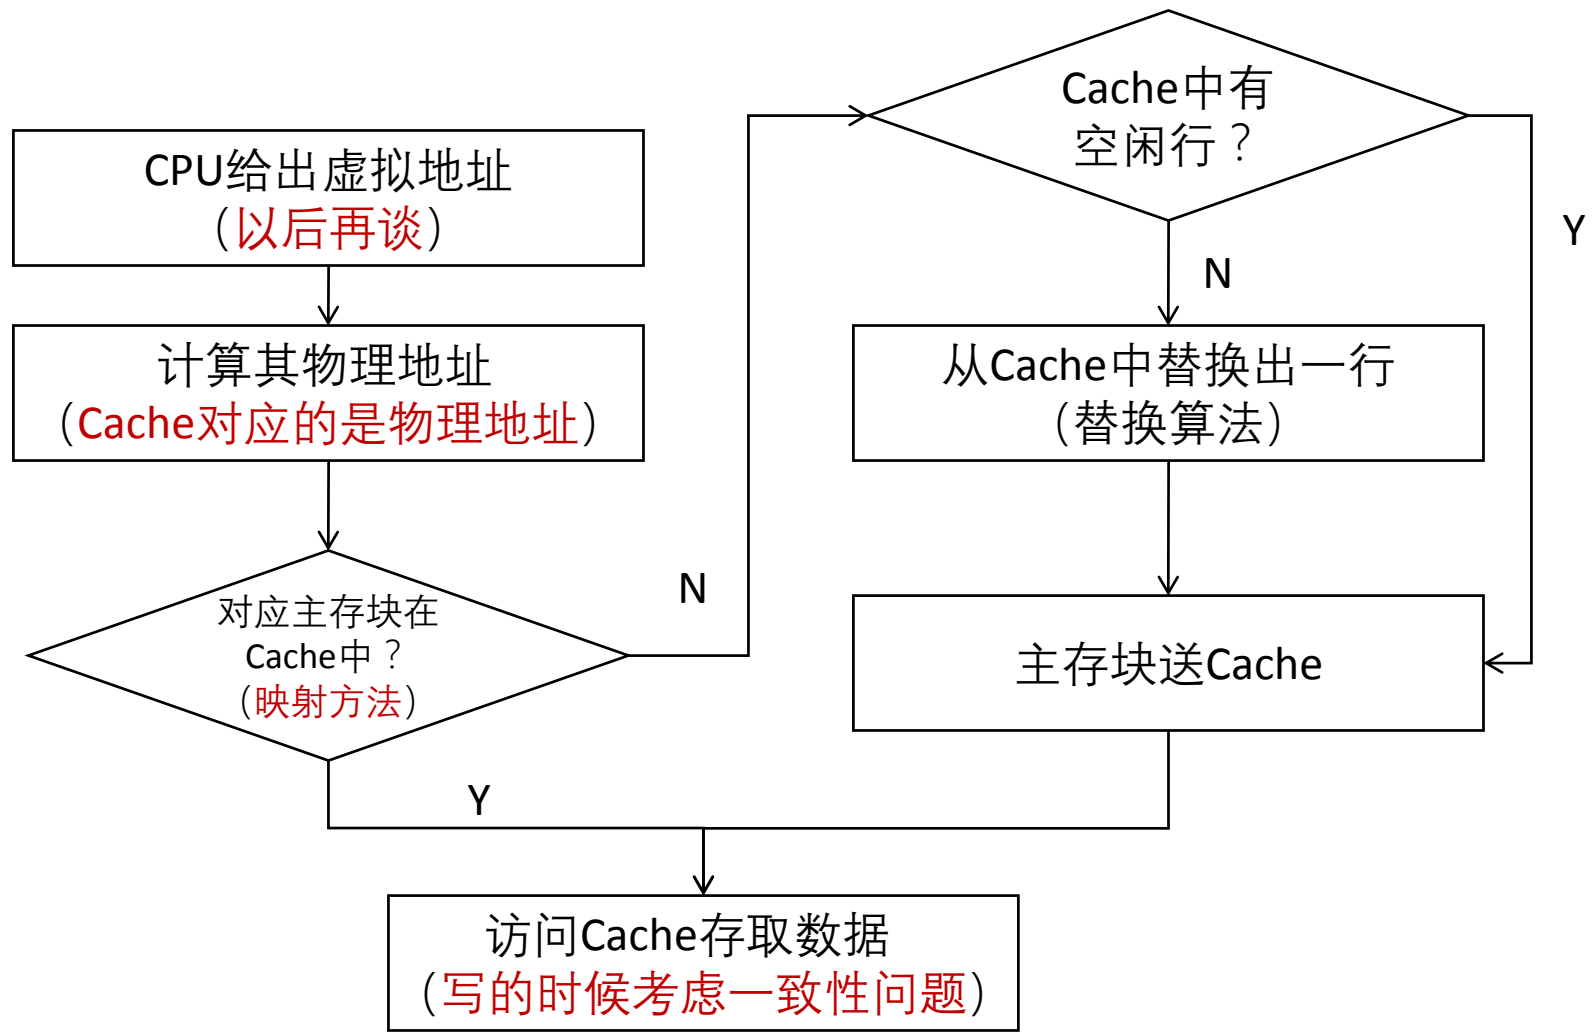
PA 3-1 Cache的模拟

- 问题二：Cache中主存块的替换算法
 - 盘子摆满了怎么办？
 - 根据程序特性各有优劣（略，课本pg. 254）
 - 先进先出法
 - 最近最少用法
 - 最近不经常用法
 - 随机替换算法

PA 3-1 Cache的模拟

- 问题三：Cache一致性问题
 - 发生于Cache被写了之后，Cache和主存内容不一致了
- 通常两种策略（略，课本pg. 254）
 - 全写法（write through）
 - 写分配法（write allocate）
 - 非写分配法（not write allocate）
 - 回写法（write back）
 - 需要额外设置脏位

CPU访问Cache的过程



PA 3-1 Cache的模拟（要求）

- 在NEMU中实现一个cache，它的性质如下：
 1. cache block存储空间的大小为64B
 2. cache存储空间的大小为64KB
 3. 8-way set associative
 4. 标志位只需要valid bit即可
 5. 替换算法采用随机方式
 6. write through
 7. not write allocate

PA 3-1 Cache的模拟 (NEMU代码)

- 第一步：编辑include/config.h

```
#define CACHE_ENABLED
```

PA 3-1 Cache的模拟（NEMU代码）

- **第二步：创建nemu/include/memory/cache.h**
 - 在里面定义一个Cache行所对应的结构体，假设名称为CacheLine
 - 结构的几个要点
 - 标志位有哪些？（只需要valid bit即可）
 - 标记部分多少位？（8-way set associative, cache block存储空间的大小为64B）
 - 数据区怎么表示？（cache block存储空间的大小为64B）

PA 3-1 Cache的模拟（NEMU代码）

- **第三步：创建nemu/src/memory/cache.c**
 - 在里面为模拟Cache分配存储空间，也就是在cache.c中定义一个全局变量，其形式为在cache.h中定义的CacheLine类型的数组
 - 因为是用内存中的数组模拟的cache，所以完成模拟后性能没法提升
 - 该数组的要点
 - Cache该有多少行？（cache block存储空间的大小为64B, cache存储空间的大小为64KB）

PA 3-1 Cache的模拟 (NEMU代码)

- **第四步：编辑nemu/include/memory/cache.h**
 - 在里面声明一些cache所提供的函数
 - `init_cache();`
 - 初始化cache，核心就是把valid bit都清0
 - `uint32_t cache_read(paddr_t paddr, size_t len, CacheLine * cache);`
 - 读cache
 - 前两个参数分别是物理地址和读的字节数
 - 最后一个参数就是cache数组的首地址，假设在cache.h中定义的Cache行的结构体名称为CacheLine
 - 返回值为读出的数据
 - `void cache_write(paddr_t paddr, size_t len, uint32_t data, CacheLine * cache);`
 - 写cache
 - 除data参数是待写的数据外，其它参数含义和cache_read()相同
 - 不需要返回值

注意数据跨cache行的情形！

PA 3-1 Cache的模拟 (NEMU代码)

- **第五步：编辑nemu/src/memory/cache.c**
 - 实现在cache.h中所声明的函数
 - init_cache();
 - 初始化cache，核心就是把valid bit都清0
 - uint32_t cache_read(paddr_t paddr, size_t len, CacheLine * cache);
 - 读cache
 - 根据paddr找到标记、组号、与块内地址
 - 根据组号去定位相应的组（起始Cache行号）
 - 与组内的CacheLine比较标记和有效位
 - 命中怎样？不命中（缺失）又怎样？
 - 组满了怎办？（**随机替换算法**）
 - void cache_write(paddr_t paddr, size_t len, uint32_t data, CacheLine * cache);
 - 写cache
 - 和cache_read()采用同样过程根据paddr定位CacheLine
 - 命中怎样？不命中（缺失）又怎样？（**not write allocate**）
 - 写cache，同时主存里面对应的块怎么办？（**write through**）

注意数据跨cache行的情形！

PA 3-1 Cache的模拟（NEMU代码）

- **第六步：编辑nemu/src/memory/memory.c**
 - #include “memory/cache.h”
 - 在init_mem()函数中调用init_cache()
 - 加入条件编译选项以便日后通过修改include/config.h来跳过cache相关代码
 - 具体仿照教程中（或后页）针对paddr_read()和paddr_write()的修改方法
 - 在paddr_read()和paddr_write()中分别通过cache_read()和cache_write()函数来实现对物理地址的读写
 - 可以设置一个简单的模拟计时器，如果cache命中则时间+10，cache缺失则时间+100，比较一下模拟的时间消耗有什么变化
 - 也可以加入对cache命中率的统计

PA 3-1 Cache的模拟 (NEMU代码)

```
uint32_t paddr_read(paddr_t paddr, size_t len) {
    uint32_t ret = 0;
#ifdef CACHE_ENABLED
        ret = cache_read(paddr, len, &L1_dcache);
#else
        ret = hw_mem_read(paddr, len);
#endif
    return ret;
}

void paddr_write(paddr_t paddr, size_t len, uint32_t data) {
#ifdef CACHE_ENABLED
        cache_write(paddr, len, data, &L1_dcache);
#else
        hw_mem_write(paddr, len, data);
#endif
}
```

nemu/src/memory/memory.c

提交时间

- PA 3-1 截止时间
 - 待定

祝大家学习快乐，身心健康！

欢迎大家踊跃参加问卷调查